


Fracao dos flops executada na GPU vs split otimo

data/gpu_traces_poti_20260701_131857/runs | losango = $r^* = \text{cap_GPU} / (\text{cap_GPU} + \text{cap_CPU})$ medido no run



acima do losango = GPU sobrecarregada (e o gargalo, $\text{eff_gpu} \sim 1.0$ em `plot_bounds`) -- quem carrega menos a GPU termina antes